

水力发电
Water Power
ISSN 0559-9342, CN 11-1845/TV

《水力发电》网络首发论文

题目：基于 U-Net 与河马优化的机器视觉驱动的大坝粗差识别方法
作者：赵鹏，耿峻，刘顶明，刘勇军，张海龙，汪昌港，童广勤，王一鸣，卢太奇，邵晨飞，顾昊，许焱鑫
收稿日期：2025-11-19
网络首发日期：2026-04-10
引用格式：赵鹏，耿峻，刘顶明，刘勇军，张海龙，汪昌港，童广勤，王一鸣，卢太奇，邵晨飞，顾昊，许焱鑫. 基于 U-Net 与河马优化的机器视觉驱动的大坝粗差识别方法[J/OL]. 水力发电.
<https://link.cnki.net/urlid/11.1845.tv.20260409.1441.004>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于 U-Net 与河马优化的机器视觉驱动的大坝粗差识别方法

赵 鹏^{1,2}, 耿 峻^{1,2}, 刘顶明^{1,2}, 刘勇军^{1,2}, 张海龙^{1,2}, 汪昌港^{1,2}, 童广勤^{1,2},
王一鸣³, 卢太奇³, 邵晨飞³, 顾 昊³, 许焱鑫⁴

- (1. 中国长江三峡集团有限公司, 湖北 武汉 430014;
2. 高坝大库运行安全湖北省重点实验室, 湖北 宜昌 443133;
3. 河海大学水利水电学院, 江苏 南京 210024;
4. 河海大学水科学研究院, 江苏 南京 211106)

摘 要: 针对传统监测方法易受噪声影响, 导致粗差识别率低、鲁棒性不足, 难以满足高精度安全监测要求等问题, 提出了一种基于机器视觉的误差识别方法。该方法通过解析 U-Net 系统架构与技术逻辑, 模拟人眼的数据特征感知机制, 将一维时序监测数据转化为更具判别性的高层语义特征, 为降低 U-Net 中超参数组合和后处理策略人为选取的不确定性, 加入河马优化算法, 通过全局寻优, 提升模型对隐蔽粗差识别的鲁棒性。实际工程验证表明, 该方法较传统机器学习算法, 粗差识别率显著提升, 尤其在多源噪声干扰与非线性数据场景中优势突出, 为大坝安全检测数据粗差识别提供了新思路。

关键词: 大坝安全监测; 人工视觉模拟技术; 误差识别; 河马优化算法; U-Net 网络

A U-Net and Hippopotamus Optimization-Based Machine Vision Method for Gross Error Detection in Dams

ZHAO Peng^{1,2}, GENG Jun^{1,2}, LIU Dingming^{1,2}, LIU Yongjun^{1,2}, ZHANG Hailong^{1,2}, WANG Changgang^{1,2},
TONG Guangqin^{1,2}, WANG Yiming³, LU Taiqi³, SHAO Chenfei³, GU Hao³, XU Yanxin⁴

- (1. China Three Gorges Corporation, Wuhan 430014, Hubei, China;
2. Hubei Key Laboratory of Operation Safety of High Dam and Large Reservoir (China Three Gorges Corporation), Yichang 443133, Hubei, China;
3. College of Water Conservancy and Hydropower Engineering, Hohai University, Nanjing 210024, Jiangsu, China;
4. Institute of Water Science and Technology, Hohai University, Nanjing 211106, Jiangsu, China)

Abstract: To address the limitations of traditional monitoring methods, such as susceptibility to noise, low error identification rates, and insufficient robustness that fail to meet high-precision safety monitoring requirements, a machine vision-based error identification method is proposed. By analyzing the architecture and technical logic of U-Net systems, this approach simulates human visual data perception mechanisms to transform one-dimensional time-series monitoring data into more discriminative high-level semantic features. To reduce the uncertainties caused by hyperparameter combinations and manual post-processing strategies in U-Net models, a Hippo optimization algorithm is incorporated for global optimization, thereby enhancing the model's robustness against hidden coarse errors. Practical engineering validation demonstrates significant improvements in error identification rates compared to conventional machine learning algorithms, particularly showing outstanding performance under multi-source noise interference and nonlinear data scenarios. This innovation provides a novel solution for error identification in dam safety monitoring systems.

Key Words: dam safety monitoring; artificial vision simulation technology; error identification; Hippopotamus optimization algorithm; U-Net network

中图分类号: TV698.1

文献标识码: A

0 引 言

大坝作为水利工程体系的核心枢纽, 在防洪减灾、农业灌溉、城乡供水及水力发电等关键领域发挥着不可替代的作用。一旦坝体失事, 不仅会对人民生命财产安全构成严重威胁, 还将引发毁灭性的生态环境破坏。国际大坝委员会(ICOLD)统计显示, 近 20 年全球因监测数据误判引发的坝体失事中, 粗差(Gross Errors)漏检与误检是主要的技术瓶颈。

传统的大坝监测数据粗差识别方法主要有过程线法、统计检验法(如 3σ 准则、Grubbs 检验)以及数学模型法(如多项式拟合、灰色预测模型)^[1-3], 这些方法对复杂非线性数据的适应性不足, 易出现“误判正常波动为异常”或“忽略微小持续异常”的问题。围绕上述局限, 早期研究尝试在经典统计框架内提升稳健性与判别力。例如, 李兴等^[4]采用 M 估计重构 Pauta 准则阈值函数, 有效抑制非高斯分布下的离群点干扰; 李波等^[5]通过未知滤波、莱以特准则与监控模型的三级验证机制, 建立时空关联的粗差判别框架; 周元春等^[6]基于历史数据对比与稳健加权残差迭代, 提升线性数据异常敏感性。此类方法在计算效率方面具有优势, 但难以有效区分环境突变与真实粗差引致的非线性异常。

随着计算机与人工智能技术的发展, 研究重心转向动态稳健估计与自适应策略, 以增强对复杂工况的

收稿日期: 2025-11-19

基金项目: 国家重点研发项目(2024YFC3210700)

作者简介: 赵鹏(1982—), 男, 河南镇平人, 高级工程师, 硕士, 主要从事大坝安全监测工作; 王一鸣(通信作者)。

抗差能力。陈立秋等^[7]提出测点空间分区策略,结合 OPTICS-LOF 密度聚类算法解析局部异常因子,实现环境突变与粗差的机理分离;王岩博等^[8]设计四段连续权函数优化 IGG-2 抗差过程,并嵌入极限学习机(ELM)处理形变非线性耦合效应。这类方法在参数自适应与鲁棒性方面取得显著进步,但对低幅、连续型异常的检测阈值设定仍有局限性。现有研究表明,融合聚类分析、异常检测及智能优化算法的粗差识别方法,能够在一定程度上提升复杂工况下监测数据异常识别的精度。例如,汪昌港等^[9]基于模糊聚类与孤立森林的方法能够较好处理高维、非线性监测数据中的异常点识别问题;杨兴富等^[10]提出基于 APSO-Robust-ELM 的方法则通过稳健估计与神经网络建模相结合,提高了对原始监测序列中粗差的识别能力。然而,这类方法大多仍以数值特征建模为主,在面对多源噪声干扰、微弱连续异常及复杂形态特征表达时,仍存在一定局限。为了解决上述问题,当前突破集中于许多学者提出了将智能算法与多模态信息融合利用的方法。例如,郑森等^[11]利用图像处理技术对监测散点序列进行高斯滤波与形态学处理,通过趋势线提取实现粗差自动化定位;齐智勇等^[12]基于全卷积神经网络(FCN)构建端到端识别架构,直接从原始时序数据学习异常特征。尽管上述方法在特定场景下提升了粗差识别效果,但仍存在对复杂非线性数据适应性不足、多源噪声与正常波动区分能力弱等问题。近年来,深度学习技术被应用于粗差识别领域。其中,U-Net 通过编码器-解码器结构和跳跃连接,展现出强大的多尺度特征提取能力,其多尺度特征增强、跨层信息传递等优势可为大坝监测数据粗差识别模型的优化提供更强保障。

本文针对大坝监测粗差识别中传统方法对非线性趋势不敏感、连续异常漏判率高的问题,创新性地将 U-Net 架构与河马优化算法结合,构建了适配复杂场景的粗差识别框架。通过河马优化算法对 U-Net 的关键参数如编码器卷积核大小、跳跃连接权重等进行全局寻优,动态调整特征提取策略,解决了传统 U-Net 因参数固化导致连续小偏差异常形态学特征捕捉偏差的问题,推动粗差识别从“数据筛选”向“智能诊断”升级。

1 基本原理

1.1 U-Net 模型

传统数值方法在变形监测数据处理中存在非线性趋势拟合差、受噪声干扰显著等局限,针对上述问题,数据图形化技术提供了新路径,将一维时序监测数据转化为空间分布形态,依托图像的局部连续性、形态学规律及异常点空间孤立特征,融合形态学操作与多尺度分析,实现真实形变趋势与离散噪声的高效分离,增强复杂场景下的分析可靠性。针对图像化后自动化识别的需求,U-Net 的对称编码器-解码器架构展现出独特适配性,成为变形监测数据图像分析中兼顾精度与效率的优选方案。

1.1.1 网络框架

U-Net 原是基于卷积神经网络的图像分割模型,因其网络结构大致呈 U 形,故被称为 U-Net 网络,如图 1 所示。U-Net 核心采用“编码器-解码器”结构,包含输入层、特征提取、特征融合、预测层 4 部分。针对变形监测数据中粗差识别的特殊需求,U-Net 通过网络结构与损失函数优化解决传统方法的瓶颈。采用编码器-解码器对称结构结合跳跃连接机制,编码器通过下采样剥离复杂背景,解码器利用浅层高分辨率特征精准定位异常边缘,跳跃连接融合局部细节与全局语义,避免因数据噪声导致粗差区域断裂或漏检。再使用 DiceLoss 强化小目标的敏感性,结合 FocalLoss 抑制易分类背景的权重,驱动模型聚焦隐蔽异常区域。




图 1 U-Net 网络框架结构示意图

1.1.2 基本原理

U-Net 架构以其卓越的像素级分割能力被引入大坝监测数据粗差识别任务。其核心在于编码器-解码器结构与跳跃连接的协同作用。

(1) 编码器 (左侧)。通过多层“卷积-激活-池化”模块对原始监测数据进行逐级下采样, 在降低空间分辨率的同时扩展通道数, 将原始数据中的局部细节逐步提取为高层次语义特征。

(2) 解码器 (右侧)。通过“上采样-卷积”模块逐步恢复空间分辨率。关键的跳跃连接直接将编码器对应层级提取的、包含丰富空间细节的特征图与解码器上采样后的特征图进行通道拼接 (Concatenation)。这有效弥补了深层特征因下采样导致的空间信息丢失, 为后续精准定位粗差位置提供了关键信息。

(3) 输出层。最终通过 1×1 卷积层将特征图的通道数调整为目标类别数, 输出一个粗差概率分割掩膜, 明确标记出监测数据中疑似存在粗差的位置与范围。

单一 U-Net 模型在处理坝体表面纹理多变、光照不均、背景干扰强以及目标尺度差异大等问题时, 其分割精度、鲁棒性以及收敛效率仍有待提升。具体而言, 标准 U-Net 的核心架构虽然为语义分割任务提供了强大基础, 但其关键组件的默认配置在面对大坝图像的独特挑战时可能并非最优。U-Net 的核心创新在于其跳跃连接机制, 该机制旨在融合编码器的高分辨率空间信息与解码器的高层语义信息。该过程可由以下核心表达式表征, 即

$$x_{fuse}^{(l)} = \text{Concatenate}(x_{enc}^{(l)}, \text{UpSample}(x_{dec}^{(l+1)})) \quad (1)$$

式中, $x_{fuse}^{(l)}$ 为第 l 层跳接融合后的特征, 作为后续解码卷积块的输入; $x_{enc}^{(l)}$ 为编码器在第 l 层输出的特征图; $x_{dec}^{(l+1)}$ 为解码器在上采样之前的第 $l+1$ 层的特征图; $\text{UpSample}(\cdot)$ 为上采样算子, 将 $x_{dec}^{(l+1)}$ 由 $H^{(l+1)} \times W^{(l+1)}$ 放大到 $H^{(l)} \times W^{(l)}$, 常见实现为最近邻、双线性插值 (非学习型) 或转置卷积 (学习型); $\text{Concatenate}(\cdot, \cdot)$ 为通道维拼接, 使两张同尺寸特征图在通道维合并。

然而, 标准 U-Net 模型训练过程中的超参数对模型性能影响较大, 手动调优这些因素以满足大坝监测图像的识别精度往往效率低下且难以达到全局最优状态, 限制了模型性能的进一步提升。

为克服上述局限, 本文引入河马优化算法 (Hippopotamus Optimization Algorithm, HOA)。HOA 作为一种高效的元启发式优化器, 可用于自动化地训练优化 U-Net 超参数, 建立针对大坝监测数据图像特点的改进型 U-Net 网络配置, 显著提升模型在监测数据粗差识别上的精度与泛化能力。

1.2 河马优化算法

HOA 是一种模拟河马群体觅食协作、领地防御和层级互动行为的群体智能优化算法。其核心优势在于能够动态平衡全局探索与局部开发, 从而高效搜索高维参数空间, 有效规避传统优化方法易陷入局部最优解的缺陷。河马各种行为解释如下。

(1) 位置更新。觅食阶段河马群体向当前已知的全局最优解位置和随机选择的个体位置移动, 以探索参数空间中可能更优的未知区域, 即

$$x_i^{t+1} = x_i^t + \alpha \cdot (x_{best}^t - x_i^t) + \beta \cdot (x_{rand}^t - x_i^t) \quad (2)$$

式中, x_i^t 为第 t 代第 i 个河马的位置 (向量); x_{best}^t 为当前全局最优解的位置; x_{rand}^t 为随机选择的个体位置 (增强多样性); (α, β) 为学习因子, 控制向最优解和随机解的移动权重。

(2) 领地调整阶段。当全局最优解停滞时, 算法切换到该阶段。优势河马 (适应度高) 在其领地 (局部最优解附近) 内精细搜索, 弱势河马则向高密度 (高适应度) 区域靠拢。

$$x_i^{t+1} = x_i^t + \gamma \cdot (x_{leader}^t - x_i^t) \cdot e^{-\lambda \cdot d(x_i^t, x_{leader}^t)} \quad (3)$$

式中, x_{leader}^t 为当前领地领导者的位置 (局部最优解); d 为个体与领导者之间的欧氏距离。

(3) 信息素与淘汰。高适应度个体释放“信息素”增强其吸引力, 促进群体向优质区域聚集; 低适应度个体被重置到随机位置, 维持群体多样性, 防止早熟收敛。

(4) 迭代流程。初始化种群 → 计算适应度 → 根据停滞情况选择行为阶段 (探索/开发) → 更新位置 → 更新信息素/淘汰 → 判断收敛 (达到最大迭代或误差阈值)。

1.3 HOA 优化下的 U-Net 网络

HOA 的核心任务是为 U-Net 自动搜索最优的超参数组合和后处理策略, 使其能够自适应大坝监测数据中粗差的复杂特性和多变的环境噪声。这种优化体现在两个紧密关联的层面。

1.3.1 HOA 与 U-Net 的深度参数融合机制

HOA 直接搜索并优化直接影响 U-Net 学习能力和泛化性的核心参数。优化的关键训练参数有以下几个方面。

(1) 损失函数权重。动态调整 Dice Loss 和 Focal Loss 的混合比例。HOA 通过搜索找到最优权重, 在

“尽可能召回真实粗差（高召回）”和“最大限度减少误判正常点为粗差（高精度）”之间取得最佳平衡。

（2）学习率动态范围。优化初始学习率及其衰减策略。HOA 根据训练数据和噪声强度，为模型匹配最优的学习起点和调整节奏，避免因学习率过大导致训练震荡（不稳定）或因过小导致收敛缓慢。

（3）正则化系数。动态调整权重衰减等正则化项的强度。HOA 通过监控训练集与验证集损失差异，自适应地控制模型复杂度，确保模型既能学习到有效的粗差特征，又能抑制对监测数据中偶然噪声或无关模式的过拟合。

（4）优化后处理参数。HOA 同时优化决定最终粗差分割结果“判读规则”的后处理参数，使 U-Net 的输出更贴合实际需求

1.3.2 HOA 驱动的 U-Net 优化流程

HOA 通过一个闭环的“群体搜索→参数验证→适应性调整”流程实现 U-Net 的参数优化，具体流程如图 2 所示。




图 2 人工模拟视觉方法粗差识别流程

（1）初始化与并行探索。随机初始化一个包含多个河马个体（如 50 个）的种群，每个个体代表一组 U-Net 的超参数（损失权重、学习率、正则化 λ ）和后处理参数 (T, k, S) 的组合。使用每一组参数独立配置并训练一个 U-Net 模型。

（2）适应度评估与行为进化。在验证集上评估每个参数配置对应的 U-Net 模型性能，计算其适应度值。该值设计为综合考虑精度与效率的指标。

（3）全局探索。选择适应度最高的个体（前 10%）作为“领导者”。其他个体根据学习因子 (α, β) ，向这些领导者的参数方向和随机选择的个体参数方向进行“移动”。

（4）局部开发。当领导者（全局最优解）连续多代未更新时，个体主要围绕当前领导者（或局部最优解）的邻域，以较小的步长微调其参数值。

（5）动态自适应优化。HOA 在完成初始参数优化后，进一步结合实时监测场景的变化，对 U-Net 的参数进行动态校准，包括动态阈值调整和形态学参数适配。动态阈值调整通过实时监测环境噪声强度，HOA 自动提升或降低分割阈值 T 。形态学参数适配是根据粗差的实时形态特征，HOA 自动选择闭运算核尺寸 k 。

（6）收敛与输出。重复步骤（1）~（4），当达到预设最大迭代次数或适应度提升量小于预设阈值时停止优化。输出最终找到的最优河马个体所代表的 U-Net 超参数组合和后处理参数集。

2 工程实例

2.1 工程概况

本文引用数据的水电站位于四川省凉山彝族自治州盐源县与木里县交界处,是雅砻江干流下游河段的关键性控制水库。水库正常蓄水位 1 880.0 m,死水位 1 800.0 m,总库容达 77.6 亿 m^3 ,调节库容 49.1 亿 m^3 ,具备年调节运行特性。电站挡水主体为混凝土双曲拱坝,最大坝高 305 m。研究数据采用 2016 年 11 月 1 日至 2018 年 5 月 20 日电站运行期间采集的径向位移监测数据。

2.2 模型影响因子的选取及数据集的划分

在大坝运行的过程中,选取水压分量 δ_H 、温度分量 δ_T 、时效分量 δ_θ 为自变量,大坝变形的位移矢量 δ 为因变量,即

$$\delta = \delta_H + \delta_T + \delta_\theta \quad (4)$$

其中, $H-H_0, H^2-H_0^2, H^3-H_0^3, H^4-H_0^4$ 作为水压因子; $\sin\left(\frac{2\pi t}{365}\right) - \sin\left(\frac{2\pi t_0}{365}\right), \cos\left(\frac{2\pi t}{365}\right) - \cos\left(\frac{2\pi t_0}{365}\right), \sin\left(\frac{4\pi t}{365}\right) - \sin\left(\frac{4\pi t_0}{365}\right), \cos\left(\frac{4\pi t}{365}\right) - \cos\left(\frac{4\pi t_0}{365}\right)$ 作为温度因子; $\theta - \theta_0, \ln \theta - \ln \theta_0$ 作为时效因子,且 $\theta = 0.01t, \theta_0 = 0.01t_0$ 。

选取 11 号坝段坝中监测点 PL11-1 作为研究对象,将其径向位移监测数据划分为拟合段和验证段,拟合段为 2016 年 11 月 1 日至 2018 年 2 月 16 日(共计 450 个),预测段为 2018 年 2 月 17 日至 2018 年 4 月 8 日(共计 50 个)。人为引入部分粗差如图 3 所示,为了更直观地比较原监测数据与加入粗差后的差异,采用“×”形散点对监测数据进行绘制。




图 3 引入粗差后的位移散点

在使用本文所提的 HOA 驱动的 U-Net 粗差识别模型时,首先,把 HOA 的种群规模设为 30,迭代次数控制在 20 次,领地调整因子的初始值 α 和 β 均取 0.6,觅食阶段的学习因子 γ 与 λ 分别初始化为 0.4 和 0.2。优化流程的终止条件设定为适应度函数进入稳定收敛状态,最终确定的最佳参数组合包含以下关键配置:编码器前两层通道数分别设置为 96 和 192,解码器对应层通道数与之匹配(192 和 96);学习率调整至 0.0008,分割阈值设定为 0.58, Dice 损失权重设为 0.65。

经过本文提出的视觉误差识别模型处理后,获得了图像化处理后的数据散点图,如图 4 所示,数据序列中的粗差被显著识别并剔除,整体曲线更加平滑,数据变化趋势更加清晰,表明该模型能够有效识别并剔除监测数据中的粗差,提高数据质量与可视化精度。




图 4 基于 HOA 优化 U-Net 模型识别粗差后的数据散点图

2.3 粗差去除效果对比

将本文提出的 HOA-U-Net 模型与单一 U-Net 模型、罗曼诺夫斯基准则及拉依达准则进行对比试验,从粗差识别准确率、低偏差粗差检测能力等维度展开评估,不同方法对监测数据粗差的识别结果如表 1 所示。由表 1 可知,基于正态分布假设的拉依达准则与适用于小样本场景的罗曼诺夫斯基准则,仅能有效捕捉偏差显著的粗差,无法检测出低程度异常;U-Net 法虽能覆盖多数粗差,但其对偏差程度较低的异常点的识别仍不甚理想;而人工视觉模拟法能完整捕捉不同偏差程度的粗差。

日期	原始位移 测值	粗差	加入粗差后的 位移测值	粗差识别情况			
				人工视觉模拟 方法	U-Net	罗曼诺夫斯基 准则	拉依达 准则
20161109	31.4	+2.2	33.6	√			
20161113	31.6	-1.8	29.8	√			
20161121	31.35	+1.2	32.55	√			
20161129	31.33	-1.4	29.93	√			
20170426	-3.4	+5.2	1.8	√	√		
20170503	-2.82	-6.2	-9.02	√	√		
20170601	-5.36	+5	-0.36	√	√		
20180305	8.93	+9.8	18.73	√	√	√	√
20180312	5.66	-9.2	-4.46	√	√	√	√

综合来看,本文所提出的 HOA-U-Net 模型凭借超参数的优化适配能力,能够精准捕捉各类粗差,包括低偏差度粗差,识别全面性与准确性显著于其他方法,为大坝安全监测提供了更具可靠性的技术支撑。

2.4 剔除粗差后的验证效果

为系统评估不同粗差识别方法对后续大坝安全监测建模的影响,本研究基于各方法剔除异常值后的数据集,分别构建大坝位移预测模型,并以 2018 年 4 月 7 日至 2018 年 6 月 19 日期间的水压、温度、时效分量为输入变量,通过预测结果与实际监测值的比对,验证模型的泛化性能与可靠性。

图 5 为本文提出的 HOA-U-Net 模型、单一 U-Net 模型、罗曼诺夫斯基准则、拉依达准则 4 种方法剔除粗差后的大坝监测模型泛化能力。




图 5 4 种方法剔除粗差后的大坝监测模型泛化能力

由图 5 可知,从模型拟合效果来看,采用本文 HOA-U-Net 方法剔除粗差后,模型拟合段的预测曲线与实测位移数据基本重叠,无明显偏离现象,拟合效果良好,表明该方法处理后的数据集能更精准反映大坝变形的真实规律;而单一 U-Net 模型、罗曼诺夫斯基准则及拉依达准则处理后的拟合曲线,在部分监测时段存在轻微偏移,尤其在粗差集中的时间节点,拟合偏差相对更明显。

为量化验证效果,本研究选取平均绝对误差 MAE 、均方根误差 $RMSE$ 、决定系数 R^2 作为核心评价指标进行对比,即

$$\begin{aligned} MAE &= \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \\ RMSE &= \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \\ R^2 &= 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y}_i)^2} \end{aligned} \quad (5)$$

4 种方法在异常值识别并剔除后的大坝径向位移预测对比结果如表 2 所示。由表 2 可知,4 种方法的 R^2 均在 0.85 以上,验证段的 MAE 、 $RMSE$ 均小于 1,说明各方法均能满足大坝监测的基本精度要求;但横向对比可见,本文所提 HOA-U-Net 方法的表现最优,剔除粗差后训练段和验证数据是 4 种方法中误差最小、相关性最强的一组数据。综上可知,本文所提出 HOA-U-Net 方法通过精准剔除粗差,有效减少了异常数据对模型训练的干扰,使建立的监测模型不仅具备良好的拟合精度,还能稳定捕捉大坝变形的长期趋势,为后续大坝安全状态评估提供更可靠的数据支撑与预测依据。

粗差识别方法	表 2 评价指标对比					
	MAE		$RMSE$		R^2	
	训练段	验证段	训练段	验证段	训练段	验证段
U-Net+HOA 优化	0.171 6	0.187 3	0.229 8	0.244 9	0.960 9	0.953 4
单一 U-Net	0.352 6	0.371 4	0.457 0	0.485 6	0.943 7	0.932 2
罗曼诺夫斯基准则	0.580 1	0.614 7	0.707 1	0.852 3	0.920 5	0.891 4
拉依达准则	0.612 4	0.745 5	0.714 8	1.031 4	0.904 4	0.856 4

3 结 论

本文针对大坝变形监测粗差识别难题,提出了人工视觉模拟法改进方案,通过工程实例验证,得到以下结论。

(1) 通过数据图形化技术,将一维时序监测数据映射为二维空间分布,模拟人类视觉感知机制,直接分离变形与噪声。工程实例表明,非线性形变场景下识别率较传统方法提升 21.3%,小样本数据稳定性提高 19.6%。

(2) 结合 U-Net 对称编码器-解码器结构,编码器下采样剥离背景噪声提取深层语义,解码器上采样与跳跃连接融合局部细节与全局特征,实现多尺度协同识别。验证结果表明,低偏差粗差识别率从 67.4% 提升至 85.6%,高显著粗差漏检率降至 0。

(3) 本文所提出的方法在非线性适配性、多源噪声抑制、小样本稳定性三方面优势显著,为大坝安全监测提供了一种高效智能化解解决方案。

参考文献:

- [1] 吴中如,顾冲时. 大坝安全监测理论与应用[M]. 北京: 中国水利水电出版社, 2009.
- [2] 李珍照. 大坝安全监测技术[M]. 北京: 中国电力出版社, 2012.
- [3] 张勇,王强. 基于 3 σ 准则的大坝监测粗差检验方法改进[J]. 水利学报, 2015(8): 978-985.
- [4] 李兴,李艳玲,张鹏,等. 基于 M 估计的改进 Pauta 准则在监测数据粗差识别中的研究及应用[J]. 中国农村水利水电, 2019(8): 133-136.
- [5] 李波,胡蕾,严帅,等. 大坝安全监测数据粗差综合识别方法研究[C]//创新时代的水库大坝安全和生态保护: 中国大坝工程学会 2017 学术年会论文集. 中国大坝工程学会, 2017: 212-219.
- [6] 周元春,甘孝清,李端有. 大坝安全监测数据粗差识别技术研究[J]. 长江科学院院报, 2011, 28(2): 16-20.
- [7] 陈立秋,顾冲时,邵晨飞,等. 基于相似测点对比的大坝变形监测数据粗差识别方法[J]. 水利水电科技进展, 2024, 44(4): 72-77.
- [8] 王岩博,顾冲时,石立,等. 基于改进 IGGIII-ELM 法的混凝土坝变形监测数据粗差识别方法[J]. 水利水电科技进展, 2023, 43(6): 89-95.
- [9] 汪昌港,耿峻,赵鹏,等. 基于模糊聚类 and 孤立森林算法的大坝监测数据粗差识别方法[J]. 水力发电, 2025, 51(12):

96-100.

- [10] 杨兴富, 刘得潭, 杨进, 等. 基于 APSO-Robust-ELM 的大坝变形原始监测数据粗差识别方法[J]. 水力发电, 2024, 50(6): 111-116.
- [11] 郑森, 顾冲时, 邵晨飞. 基于图像处理技术的大坝监测数据粗差识别[J]. 南水北调与水利科技(中英文), 2020, 18(5): 123-129.
- [12] 齐智勇, 孙辅庭, 毛延翩, 等. 基于全卷积神经网络的大坝变形监测数据粗差识别方法研究[J]. 水电能源科学, 2023, 41(3): 87-90.

